


# Regresja liniowa prosta

-1-

(2)



$$y_i = \beta_0 + \beta_1 X_i + \xi_i, \quad i = \overline{1, n}$$

wyraz wolny  
intercept

współczynnik kierunkowy  
slope

$b_{\text{ad}}$   
łozowy

$$E\xi_i = 0$$

$$\text{Var}\xi_i = \sigma^2$$

niezależne

$$(\xi_i \sim N(0, \sigma^2))$$

$$\text{cov}(\xi_i, \xi_j) = 0$$

$(X_i, y_i)$   
zmienna

← wiadomo


objasniająca  
explanatory

objasniana  
response

$$[\beta_0, \beta_1, \sigma^2 ???]$$

← nie wiadomo

(2a)



$$\sum e_i \rightarrow \min.$$

$$\Rightarrow \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = b_1$$

$$\bar{x} = \frac{1}{n} \sum x_i$$

$$\bar{y} = \frac{1}{n} \sum y_i$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = b_0$$

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = s^2$$

(2b)

$$T = \frac{\hat{\beta}_1 - \beta_1}{S(\hat{\beta}_1)} \sim t(n-2)$$

↑  
rozkład Studenta  
z  $(n-2)$  stopniami  
swobody


$$S^2(\hat{\beta}_1) = \frac{s^2}{\sum_{i=1}^n (x_i - \bar{x})^2} ; \quad / s^2 = \hat{\sigma}^2$$

⇒ przedział ufności dla  $\beta_1$ :

$$\hat{\beta}_1 \pm t_c S(\hat{\beta}_1)$$

↑  
kwantyl rzędu  
 $1 - \frac{\alpha}{2}$  z  $t(n-2)$

$$t_c = t^*(1 - \frac{\alpha}{2}, n-2)$$



$qt(\frac{\alpha}{2}, df = n-2, \text{lower.tail} = T)$

(2c) Test istotności dla  $\beta_1$ :

$$H_0: \beta_1 = 0;$$

$$H_1: \beta_1 \neq 0$$

$$T = \frac{\hat{\beta}_1 - 0}{S(\hat{\beta}_1)}$$

$$|T| > t_c \Rightarrow \text{odrzucaamy } H_0$$


p-wartość:

$$p = P(|z| > |T|), \text{ gdzie}$$

$$z \sim t(n-2)$$

$$T = \frac{\hat{\beta}_1 - 0}{S(\hat{\beta}_1)} - \text{liczymy na podstawie danych}$$





$$Y_h = \beta_0 + \beta_1 X_h + \varepsilon_h$$

$$EY_h = \mu_h = \beta_0 + \beta_1 X_h$$

$$\Rightarrow \hat{\mu}_h = \hat{\beta}_0 + \hat{\beta}_1 X_h \quad - \text{estymator } EY_h = \mu_h$$

Przedział ufności dla  $EY_h = \mu_h$

$$T = \frac{\hat{\mu}_h - \mu_h}{s(\hat{\mu}_h)} \sim t(n-2)$$

$$s^2(\hat{\mu}_h) = s^2 \left( \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

Przedział ufn.

$$\Rightarrow \text{dla } \mu_h: \hat{\mu}_h \pm t_c s(\hat{\mu}_h)$$

④ Predykcja punktowa dla nowej wartości  $Y_h$ .

$$Y_h = \beta_0 + \beta_1 X_h + \varepsilon_h \quad - \text{wartość nowej zmiennej } Y_h$$

$$\hat{Y}_h = \hat{\mu}_h = \hat{\beta}_0 + \hat{\beta}_1 X_h \quad - \text{estymator punktowy dla } Y_h$$

$$T = \frac{Y_h - \hat{\mu}_h}{s(\text{pred})} \sim t(n-2),$$

$$s^2(\text{pred}) = s^2 \left( 1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$


Przedział predykcyjny dla  $y_n$ :

-4-

$$\hat{\mu}_n \pm t_c s(\text{pred})$$

⑤ Przedziały ufności dla wszystkich możliwych wartości  $\mu_n$  (pasmo ufności)


$$\hat{\mu}_n \pm \underset{\uparrow}{w} \cdot s(\hat{\mu}_n)$$



$$w^2 = 2 F(1-\alpha, 2, n-2) \quad kw$$

kwantyl rzędu  $1-\alpha$  z rozkładu Fishera - Snedekora z 2,  $n-2$  stopniami swobody

$$qf(1-\alpha, df1=2, df2=n-2)$$





R komendy

DataF ← data.frame ( -- )

Data F: 

y	X

LinM ← lm ( y ~ x , DataF )

LinM /  $\hat{\beta}_0, \hat{\beta}_1$

summary ( LinM )

/ wszystkie rodzaje cech modeli liniowej

LinM\$ coefficients

LinM\$ residuals

confint ( LinM )

/ wartości  $\hat{\beta}_0, \hat{\beta}_1, \dots$

— 95% przedziały ufności dla  $\beta_0, \beta_1$ .

$$⑥ \quad H_0: \beta_1 = 0 \quad ; \quad H_1: \beta_1 \neq 0$$

$$T = \frac{\hat{\beta}_1}{s(\hat{\beta}_1)}$$

$$s^2(\hat{\beta}_1) = \frac{s^2}{\sum_i (x_i - \bar{x})^2} \quad ; \quad s^2 = \frac{1}{n-2} \sum_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Funkcja mocy testu:

$$\pi(a) = P_{\beta_1=a} (|T| > t_c), \quad \forall a \neq 0$$

$$a=0 \Rightarrow T \sim t(n-2, \delta)$$

↑  
niecentralny rozkład  
Studenta z (n-2) st. sw i  
parametrem niecentralności:  
 $\delta = \frac{\beta_1}{\sigma(\hat{\beta}_1)}$

$$\frac{q}{2} \text{ } \downarrow \quad t(\dots, df=, ncp=)$$

"δ"

$$n, SSX = \sum_{i=1}^n (x_i - \bar{x})^2, \quad \sigma^2 \text{ - } \text{scg wiadome}$$

$$\Rightarrow \sigma^2(\hat{\beta}_1) = \frac{\sigma^2}{SSX}$$

$$\delta = \frac{\beta_1}{\sigma(\hat{\beta}_1)}$$

$$\Rightarrow T \sim t(n-2, \delta)$$

$$\pi(\beta_1=a) = P_{\beta_1=a} (|T| > t_c) =$$

$$= P_{\beta_1=a} (T < -t_c) + P_{\beta_1=a} (T > t_c)$$



$$\textcircled{7} \quad X = (X_1 \dots X_{200})^T \sim N(0, I_{200})$$

$$Y = 5 + \beta_1 X + \xi$$

$$\begin{pmatrix} X_1 \\ \vdots \\ X_{200} \end{pmatrix} \mapsto \begin{pmatrix} Y_1 \\ \vdots \\ Y_{200} \end{pmatrix} \mapsto T = \frac{\hat{\beta}_1 - 0}{S(\hat{\beta}_1)} \mapsto \dots$$

$$\mapsto |T| > t_c ? \mapsto \begin{cases} 1, & |T| > t_c \\ 0, & |T| \leq t_c \end{cases}$$

1000 razy  
 $\Rightarrow$

$$\begin{pmatrix} 1 \\ 0 \\ 0 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$$

$\leftarrow 1000 \times 1$

$$\mapsto \hat{p} = \frac{\#\{1\}}{1000}$$

$\nearrow$   
 częstość  
 odrzuceń

$$Y = 5 + \beta_1 X + \xi$$

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

$$(a) - (\xi \sim N(0, I)) - (c)$$

$$(b) - (\xi \sim \cancel{N(0, I)}) - (d)$$

$\downarrow$   
 $\hat{p}$  - estymator  
 $P(\text{błąd I rz.})$

$\downarrow$   
 $\hat{p}$  - estymator  
 mocy testu  
 $(1 - P(\text{błąd II rz.}))$

$\Rightarrow$  porównać wyniki z wartościami teoretycznymi dla  $P(\text{błąd I rz.})$  oraz mocy test (liczonymi przy założeniu  $\xi \sim N(0, I)$ )