

Modele liniowe

Michał Kos

Uniwersytet Wrocławski

Plan wykładu

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Regresja liniowa wieloraka

Pomysł zawarty w regresji liniowej prostej można łatwo uogólnić na sytuację w której zmiennych objaśniających jest więcej niż jedna. Wówczas z każdą wartością zmiennej odpowiedzi Y_i stowarzyszony jest wektor wartości kilku regresorów $X_i = (X_{i1}, \dots, X_{ip-1})'$:

Model teoretyczny regresji liniowej wielorakiej w postaci skalarnej

Teoretyczny model dla regresji liniowej wielorakiej:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \dots + X_{ip-1}\beta_{p-1} + \epsilon_i \quad i = 1, \dots, n$$

gdzie: $\epsilon_1, \dots, \epsilon_n$ – błędy losowe, ciąg niezależnych zmiennych losowych z rozkładu normalnego o średniej 0 i wariancji σ^2

X_{ij} – wartość j-tej zmiennej niezależnej stowarzyszona z i-tą obserwacją zmiennej zależnej Y_i ,

β_0 – Intercept,

$\beta_k \quad k = 1, \dots, p - 1$ – parametry regresji związane z odpowiadającymi im zmiennymi objaśniającymi ("Slope"-y).

Regresja liniowa wieloraka – ważne przykłady

Łatwo zauważyć, że takie uogólnienie jest mocno pożądane. Zwykle badacz podejrzewa, że na badane zjawisko ma wpływ więcej niż jedna cecha.

Regresja liniowa wieloraka – ważne przykłady

Łatwo zauważyć, że takie uogólnienie jest mocno pożądane. Zwykle badacz podejrzewa, że na badane zjawisko ma wpływ więcej niż jedna cecha.

Przykład 1

Badania medyczne wskazują na to, że ciśnienie pacjenta Y_i zależy od wielu czynników np. wiek, BMI, przewlekłe stany chorobowe, pula genetyczna $X_i = (X_{i1}, \dots, X_{ip-1})'$.

Regresja liniowa wieloraka – ważne przykłady

Łatwo zauważyć, że takie uogólnienie jest mocno pożądane. Zwykle badacz podejrzewa, że na badane zjawisko ma wpływ więcej niż jedna cecha.

Przykład 1

Badania medyczne wskazują na to, że ciśnienie pacjenta Y_i zależy od wielu czynników np. wiek, BMI, przewlekłe stany chorobowe, pula genetyczna $X_i = (X_{i1}, \dots, X_{ip-1})'$.

Stosowanie regresji liniowej wielorakiej umożliwia równoczesną analizę wpływu kilku cech. Ponadto, (przy odpowiedniej wstępnej obróbce danych) daje możliwość porównywania siły poszczególnych cech.

Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Regresja liniowa wieloraka pozwala na modelowanie relacji nieliniowych.

Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Regresja liniowa wieloraka pozwala na modelowanie relacji nieliniowych.

Przykład 2

Z fizyki wiemy, że przemieszczenie w swobodnym spadku w polu grawitacyjnym ziemi wyraża się następującym wzorem:

$$Y(t) = \beta_0 + t\beta_1 + t^2\beta_2$$

gdzie: β_0 – początkowe położenie ciała, β_1 – początkowa szybkość ciała (w kierunku y), $\beta_2 = -\frac{g}{2}$ g – przyspieszenie ziemskie, t – czas, $Y(t)$ – położenie w chwili t .

Powyższa relacja w oczywisty sposób jest funkcją kwadratową. W związku z tym dla par obserwacji $\{(Y_i, t_i)\}_{i=1}^n$ model uzyskany przy użyciu regresji liniowej prostej (dopasowujący prostą do danych; $\hat{Y}_i = \hat{\beta}_0 + t_i\hat{\beta}_1$) będzie nieadekwatny.

Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Przykład 2 c.d.

$$Y(t) = \beta_0 + t\beta_1 + t^2\beta_2$$

Jednakże, alternatywnie, do zbioru danych $\{(Y_i, t_i)\}_{i=1}^n$ możemy użyć modelu regresji wielorakiej następującej postaci:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i$$

gdzie $X_{i1} = t_i$, $X_{i2} = t_i^2$, oraz ϵ_i – błąd związany z pomiarem położenia ciała (Y_i) w chwili t_i .

Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Przykład 2 c.d.

$$Y(t) = \beta_0 + t\beta_1 + t^2\beta_2$$

Jednakże, alternatywnie, do zbioru danych $\{(Y_i, t_i)\}_{i=1}^n$ możemy użyć modelu regresji wielorakiej następującej postaci:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i$$

gdzie $X_{i1} = t_i$, $X_{i2} = t_i^2$, oraz ϵ_i – błąd związany z pomiarem położenia ciała (Y_i) w chwili t_i .

Powyższy model umożliwia dopasowanie funkcji kwadratowej do danych. Stosując analogiczne rozumowanie możemy dopasować do danych np. wielomian dowolnego stopnia lub inne nieliniowe relacje.

Regresja liniowa wieloraka – ważne przykłady (interakcja)

Czasami naturalnym wydaje się, że równoczesne występowanie kilku czynników ma dodatkowy pozytywny wpływ na zmienną odpowiedzi Y .

Regresja liniowa wieloraka – ważne przykłady (interakcja)

Czasami naturalnym wydaje się, że równoczesne występowanie kilku czynników ma dodatkowy pozytywny wpływ na zmienną odpowiedzi Y .

Przykład 3

Na zbiory rolnicze (Y) ma wpływ np. skład podłoża (np. nawóz) oraz odpowiednie nawodnienie. Możemy zatem zastosować następujący model:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i \quad i = 1, \dots, n$$

gdzie X_{i1} – zmienna niezależna będąca indykatorem opisującym to czy na polu Y_i zastosowano nawóz ($X_{i1} = 1$) czy nie zastosowano nawożenia ($X_{i1} = 0$),

X_{i2} – zmienna niezależna opisując poziom nawodnienia obszaru Y_i np. ilość wody na m^2 w jednostce czasu.

Regresja liniowa wieloraka – ważne przykłady (interakcja)

Przykład 3 c.d.

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i \quad i = 1, \dots, n$$

Zgodnie z powyższym modelem zysk dla każdego czynnika (nawożenie, nawadnianie) jest niezależny. Wydaje się jednak, że równoczesne zastosowanie optymalnych nawozu i nawodnienia może skutkować pewnym "bonusowym" plonem ("1+1 = 5").

Regresja liniowa wieloraka – ważne przykłady (interakcja)

Przykład 3 c.d.

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i \quad i = 1, \dots, n$$

Zgodnie z powyższym modelem zysk dla każdego czynnika (nawożenie, nawadnianie) jest niezależny. Wydaje się jednak, że równoczesne zastosowanie optymalnych nawozu i nawodnienia może skutkować pewnym "bonusowym" plonem ("1+1 = 5").

Powyższą obserwację możemy uwzględnić wykorzystując tzw. model liniowy z interakcjami:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + X_{i1}X_{i2}\beta_3 + \epsilon_i \quad i = 1, \dots, n$$

W powyższym modelu składnik $X_{i1}X_{i2}\beta_3$ opisuje "bonusowy" wpływ interakcji pomiędzy zmiennymi X_{i1} i X_{i2} . Wprowadzając oznaczenie $X_{i3} = X_{i1}X_{i2}$ otrzymujemy model regresji liniowej wielorakiej postaci:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + X_{i3}\beta_3 + \epsilon_i \quad i = 1, \dots, n$$

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Model teoretyczny w postaci skalarnej

Model teoretyczny w postaci skalarnej

Poznaliśmy już teoretyczny model dla regresji liniowej prostej w zapisie skalarным:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \dots + X_{ip-1}\beta_{p-1} + \epsilon_i \quad i = 1, \dots, n$$

gdzie $\epsilon_1, \dots, \epsilon_n$ – ciąg niezależnych zmiennych losowych z rozkładu normalnego o średniej 0 i wariancji σ^2 .

Model ten bardzo często zapisywany jest alternatywnie w postaci macierzowej:

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np-1} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

Model teoretyczny w postaci macierzowej – oznaczenia

Wprowadźmy następujące oznaczenia:

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}; \quad \mathbb{X} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np-1} \end{pmatrix}$$
$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix}; \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

gdzie:

$Y \in \mathbb{R}^n$ nazywamy wektorem odpowiedzi,

$\mathbb{X} \in M_{n \times p}$ nazywamy macierzą planu lub eksperymentu (deterministyczna macierz),

$\beta \in \mathbb{R}^p$ nazywamy wektorem parametrów (deterministyczny wektor),

$\epsilon \in \mathbb{R}^n$ nazywamy wektorem błędów losowych.

Model teoretyczny w postaci macierzowej

Model teoretyczny w postaci macierzowej

Model teoretyczny dla regresji liniowej wielorakiej w zapisie macierzowym ma postać:

$$Y = \mathbb{X}\beta + \epsilon$$

gdzie $\epsilon \in \mathbb{R}^n$ jest wektorem losowym z rozkładu normalnego $N(0_n, \sigma^2 \mathbb{I}_n)$.

Model teoretyczny w postaci macierzowej

Model teoretyczny w postaci macierzowej

Model teoretyczny dla regresji liniowej wielorakiej w zapisie macierzowym ma postać:

$$Y = X\beta + \epsilon$$

gdzie $\epsilon \in \mathbb{R}^n$ jest wektorem losowym z rozkładu normalnego $N(0_n, \sigma^2 \mathbb{I}_n)$.

Ma on zatem dokładnie tę samą postać co teoretyczny model regresji liniowej prostej. Jedyną różnicą jest liczba kolumn w macierzy planu X i liczba parametrów w wektorze β :

równanie		Y	$=$	X	β	$+$	ϵ
wymiary (macierzowo)		$n \times 1$		$n \times p$	$p \times 1$		$n \times 1$

Uwaga o notacji w wektorze β i macierzy \mathbb{X}

W wektorze $\beta = (\beta_0, \beta_1, \dots, \beta_{p-1})'$ jest p elementów, przy czym numerujemy je od 0 do $p - 1$, zachowując "wyjątkowość" parametru β_0 jako interceptu. Pozostałe $p - 1$ elementów opisuje wpływ poszczególnych regresorów.

Podobnie w macierzy planu \mathbb{X} jest p kolumn. Pierwsza kolumna to ciąg jedynek ($\forall i$) $\mathbb{X}_{i1} = 1$ stowarzyszony z Interceptem. Kolejne kolumny opisują zachowanie poszczególnych zmiennych niezależnych dla kolejnych obserwacji ($\forall i, j \geq 2$) $\mathbb{X}_{ij} = X_{ij-1}$

$$\mathbb{X} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np-1} \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix};$$

Tw. 1

Jeżeli $B = c + DA \in \mathbb{R}^m$, jest afinicznym przekształceniem wektora losowego $A \sim N(\mu, \Sigma) \in \mathbb{R}^n$, gdzie $c \in \mathbb{R}^m$ jest deterministycznym wektorem oraz $D \in \mathbb{M}_{m \times n}$ jest deterministyczną macierzą, wówczas:

$$B \sim N(c + D\mu, D\Sigma D')$$

Na podstawie Tw. 1 otrzymujemy w natychmiastowy sposób że:

$$Y \sim N(\mathbb{X}\beta, \sigma^2\mathbb{I})$$

Czyli:

- ① Wektor Y pochodzi z n -wymiarowego rozkładu normalnego,
- ② Wartość oczekiwana jest liniowym przekształceniem: $E(Y) = \mathbb{X}\beta$,
- ③ Macierz kowariancji jest postaci: $\text{Cov}(Y) = \sigma^2\mathbb{I}$:
 - Y_1, \dots, Y_n jest ciągiem niezależnych zmiennych losowych o stałej wariancji σ^2 .

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji**
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Metoda najmniejszych kwadratów

Kryterium estymacji parametrów metodą najmniejszych kwadratów w regresji liniowej wielorakiej:

$$\hat{\beta} = \arg \min_b \sum_{i=1}^n (Y_i - (b_0 + X_{i1}b_1 + \dots + X_{ip-1}b_{p-1}))^2 = \arg \min_b \sum_{i=1}^n e_i^2(b)$$

gdzie $b = (b_0, b_1, \dots, b_{p-1})' \in \mathbb{R}^p$, $e_i(b)$ – ciąg residuów stowarzyszony z wektorem b .

W notacji macierzowej możemy zapisać powyższe równanie w następującej postaci:

$$\hat{\beta} = \arg \min_b \|Y - \mathbb{X}b\|_2^2 = \arg \min_b \|e(b)\|_2^2$$

Residua dla estymatora OLS

W przypadku estymatora najmniejszych kwadratów we wzorze na residuum (wektor residuów) będziemy pomijać argument funkcji:

$$e_i := e_i(\hat{\beta}); \quad e := e(\hat{\beta})$$

Estymator metody najmniejszych kwadratów (1)

Zapis macierzowy umożliwia elegancki sposób wyrażenia estymatora metody najmniejszych kwadratów. Wyznamy pochodną z funkcji $\|Y - \mathbb{X}b\|_2^2$ po współczynnikach:

$$\begin{aligned}\partial_{b_0} \|Y - \mathbb{X}b\|_2^2 &= \partial_{b_0} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 = \\ &= \sum_{i=1}^n -2\mathbb{X}_{i1}(Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1})) = \\ &= -2\mathbb{X}'_{\bullet 1}(Y - \mathbb{X}b) = -2\mathbb{X}'_{\bullet 1}e(b)\end{aligned}$$

gdzie $\mathbb{X}_{\bullet j}$ oznacza j -tą kolumnę w macierzy \mathbb{X} .

Estymator metody najmniejszych kwadratów (2)

W analogiczny sposób można uzyskać pochodną po dowolnym b_i . Podsumowując, pochodna po b_i z funkcji $\|Y - \mathbb{X}b\|_2^2$ jest równa przeskalowanemu (-2) iloczynowi skalarnemu pomiędzy kolumną związaną z i -tym współczynnikiem w wektorze b a wektorem residuów $e(b)$:

$$\partial_{b_i} \|Y - \mathbb{X}b\|_2^2 = -2\mathbb{X}'_{\bullet i}(Y - \mathbb{X}b)$$

Zapis wykorzystujący gradient funkcji ($\nabla_s f(s) = (\partial_{s_1} f(s), \dots, \partial_{s_d} f(s))'$) umożliwia uzyskanie jeszcze bardziej zwartej postaci:

Gradient funkcji $\|Y - \mathbb{X}b\|_2^2$

$$\nabla_b \|Y - \mathbb{X}b\|_2^2 = -2\mathbb{X}'(Y - \mathbb{X}b)$$

Estymator metody najmniejszych kwadratów (3)

Wykonując dalsze przekształcenia łatwo jest wyznaczyć hesjan funkcji $\|Y - \mathbb{X}b\|_2^2$:

$$\begin{aligned}Hes_{jk} &= \partial_{b_{k-1}}(\partial_{b_{j-1}}\|Y - \mathbb{X}b\|_2^2) = \\&= \partial_{b_{k-1}} \sum_{i=1}^n -2\mathbb{X}_{ij}(Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1})) = \\&= \sum_{i=1}^n 2\mathbb{X}_{ij}\mathbb{X}_{ik} = 2(\mathbb{X}'\mathbb{X})_{jk}\end{aligned}$$

Zatem hesjan funkcji $\|Y - \mathbb{X}b\|_2^2$ w macierzowej postaci ma formę:

Hesjan funkcji $\|Y - \mathbb{X}b\|_2^2$

$$Hes = 2\mathbb{X}'\mathbb{X}$$

Estymator metody najmniejszych kwadratów (4)

Łatwo pokazać, że hesjan $Hes = 2\mathbb{X}'\mathbb{X}$ jest dodatnio określony:

Niech $v \in \mathbb{R}^n$ będzie dowolnym niezerowym wektorem. Wówczas

$$v'(Hes)v = 2v'\mathbb{X}'\mathbb{X}v = 2(\mathbb{X}v)'(\mathbb{X}v) = 2\|\mathbb{X}v\|_2^2 \geq 0$$

W konsekwencji, ekstremum wyznaczone za pomocą przyrównania gradientu do zera musi być minimum dla funkcji $\|Y - \mathbb{X}b\|_2^2$ i stanowi estymator OLS:

$$-2\mathbb{X}'(Y - \mathbb{X}\hat{\beta}) = 0 \quad \Leftrightarrow \quad \mathbb{X}'\mathbb{X}\hat{\beta} = \mathbb{X}'Y$$

Ostatecznie uzyskujemy:

Estymator metody najmniejszych kwadratów

Założmy, że macierz $\mathbb{X}'\mathbb{X}$ jest odwracalna ($\det(\mathbb{X}'\mathbb{X}) \neq 0$). Wówczas estymator metody najmniejszych kwadratów ma postać:

$$\hat{\beta} = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'Y$$

Uwaga!

Można pokazać, że założenie o odwracalności macierzy $\mathbb{X}'\mathbb{X}$ jest równoważne liniowej niezależności kolumn macierzy \mathbb{X} .

W wielu sytuacjach jest to naturalny warunek w kontekście modeli liniowych i od tej pory na wykładzie będzie on zakładany.

Estymator metody największej wiarygodności (MLE)

Aby wyznaczyć estymator największej wiarygodności musimy znaleźć wektor maksymalizujący funkcję wiarygodności dla zbioru zmiennych odpowiedzi Y_1, \dots, Y_n :

$$L(b, z^2 | Y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi z^2}} \exp \left(-\frac{1}{2z^2} (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 \right)$$

Estymator metody największej wiarygodności (MLE)

Aby wyznaczyć estymator największej wiarygodności musimy znaleźć wektor maksymalizujący funkcję wiarygodności dla zbioru zmiennych odpowiedzi Y_1, \dots, Y_n :

$$L(b, z^2 | Y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi z^2}} \exp \left(-\frac{1}{2z^2} (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 \right)$$

Logarytm funkcji wiarygodności:

$$\log(L(b, z^2 | Y)) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log z^2 - \frac{1}{2z^2} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2$$

Estymator metody największej wiarygodności (MLE)

Aby wyznaczyć estymator największej wiarygodności musimy znaleźć wektor maksymalizujący funkcję wiarygodności dla zbioru zmiennych odpowiedzi Y_1, \dots, Y_n :

$$L(b, z^2 | Y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi z^2}} \exp \left(-\frac{1}{2z^2} (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 \right)$$

Logarytm funkcji wiarygodności:

$$\log(L(b, z^2 | Y)) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log z^2 - \frac{1}{2z^2} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2$$

Z powyższej postaci widać, że dla dowolnej wartości z^2 , maksymalizacja po wektorze b jest równoważna minimalizacji wyrażenia:

$$\sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2$$

czyli minimalizacji sumy kwadratów residuów. Wynika stąd, że estymatory $\hat{\beta}$ uzyskane metodami ML i OLS są takie same.

Metoda największej wiarygodności (Maximum Likelihood)

Aby wyznaczyć estymator ML dla σ^2 musimy policzyć pochodną z logarytmu funkcji wiarygodności po z^2 i przyrównać do 0 (ekstremum) oraz sprawdzić, że rozwiązanie faktycznie maksymalizuje badaną funkcję. Estimator ML jest postaci:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}\hat{\beta}_0 + \mathbb{X}_{i2}\hat{\beta}_1 + \dots + \mathbb{X}_{ip}\hat{\beta}_{p-1}))^2$$

Można pokazać, że jest on obciążony. Nieobciążony estymator (zwykle stosowany) ma postać:

$$s^2 = \frac{1}{n-p} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}\hat{\beta}_0 + \mathbb{X}_{i2}\hat{\beta}_1 + \dots + \mathbb{X}_{ip}\hat{\beta}_{p-1}))^2 = \frac{1}{n-p} \|Y - \mathbb{X}\hat{\beta}\|_2^2$$

$$E(s^2) = \sigma^2$$

Znając estymator $\hat{\beta}$ w łatwy sposób możemy wyznaczyć przewidywane wartości zmiennej objaśnianej dla wartości ze zbioru danych

$Y = (Y_1, \dots, Y_n)$:

$$\hat{Y} = \mathbb{X}\hat{\beta}$$

Znając estymator $\hat{\beta}$ w łatwy sposób możemy wyznaczyć przewidywane wartości zmiennej objaśnianej dla wartości ze zbioru danych

$Y = (Y_1, \dots, Y_n)$:

$$\hat{Y} = \mathbb{X}\hat{\beta}$$

W analogiczny sposób możemy dokonać predykcji dla dowolnej wartości $Y \in \mathbb{R}$.

Założmy że chcemy znaleźć przewidywaną wartość zmiennej objaśnianej \tilde{Y} dla wektora wartości zmiennych objaśniających $\tilde{X} = (1, \tilde{X}_1, \dots, \tilde{X}_{p-1})$ (np. nowy wiersz w macierzy planu) na podstawie skonstruowanego modelu empirycznego. Wówczas:

$$\hat{\tilde{Y}} = \tilde{X}\hat{\beta}$$

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów**
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Rozkład estymatora $\hat{\beta}$

Estymator otrzymany metodą najmniejszych kwadratów ma następujący rozkład:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbb{X}'\mathbb{X})^{-1})$$

- normalność wynika z faktu, że $\hat{\beta} = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'Y$ jest liniowym przekształceniem wektora $Y \sim N(\mathbb{X}\beta, \sigma^2\mathbb{I})$,

- wartość oczekiwana:

$$E(\hat{\beta}) = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'E(Y) = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}\beta = \beta \text{ (estymator jest nieobciążony),}$$

- macierz kowariancji:

$$\begin{aligned} \text{Cov}(\hat{\beta}) &= (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\sigma^2\mathbb{I}((\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}')' = \\ &= \sigma^2(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}((\mathbb{X}'\mathbb{X})^{-1})' = \sigma^2((\mathbb{X}'\mathbb{X})')^{-1} = \sigma^2(\mathbb{X}'\mathbb{X})^{-1} \end{aligned}$$

W dowodzie postaci macierzy kowariancji korzystaliśmy z własności macierzy: $(AB)' = B'A'$ oraz $(A^{-1})' = (A')^{-1}$

Macierz H

Wprowadźmy następujące oznaczenie na macierz

$$H = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'$$

Macierz H jest ważnym obiektem w analizie modeli liniowych. Przy jej pomocy można w łatwy sposób wyrazić predykcję wektora odpowiedzi \hat{Y} i wektor residuów e :

Predykcja \hat{Y} i residua wyrażone przy pomocy macierzy H

$$\hat{Y} = \mathbb{X}\hat{\beta} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'Y = HY$$

$$e = Y - \hat{Y} = (\mathbb{I} - H)Y$$

Kolejną ważną własnością macierzy H jest:

H – macierz rzutu ortogonalnego na $\text{Lin}(X)$

Macierz H jest macierzą rzutu ortogonalnego na przestrzeń $\text{Lin}(X)$ rozpiętą na kolumnach macierzy eksperymentu.

Aby to wykazać skorzystamy z charakteryzacji rzutów ortogonalnych z algebry liniowej:

dowolna macierz P jest macierzą rzutu ortogonalnego wtedy i tylko wtedy gdy macierz P jest symetryczna ($P = P'$) i idempotentna ($P^2 = P$).

Aby to wykazać skorzystamy z charakteryzacji rzutów ortogonalnych z algebry liniowej:

dowolna macierz P jest macierzą rzutu ortogonalnego wtedy i tylko wtedy gdy macierz P jest symetryczna ($P = P'$) i idempotentna ($P^2 = P$).

Łatwo pokazać, że macierz H ma obie powyższe cechy:

- symetryczność: $H' = (\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}')' = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' = H$
- idempotentność:
$$H^2 = (\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}')(\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}') = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' = H$$

Macierz H

Pozostaje wykazać że przestrzeń na którą rzutuje macierz H to $Lin(\mathbb{X})$.

Rozważmy dowolny wektor $v \in \mathbb{R}^n$ i rozłóżmy go na dwie składowe $v = v_1 + v_2$, w taki sposób że $v_1 \in Lin(\mathbb{X})$, a $v_2 \perp Lin(\mathbb{X})$. Ponieważ v_1 należy do przestrzeni $Lin(\mathbb{X})$ zatem możemy go wyrazić jako kombinację liniową kolumn z macierzy \mathbb{X} :

$$v_1 = \mathbb{X}w$$

gdzie $w \in \mathbb{R}^p$. Z drugiej strony ze względu na to, że wektor v_2 należy do przestrzeni ortogonalnej do $Lin(\mathbb{X})$, wynika to że dla dowolnej kolumny w macierzy \mathbb{X} , iloczyn skalarny pomiędzy kolumną a wektorem v_2 wynosi zero. Stąd:

$$\mathbb{X}'v_2 = 0$$

Wykorzystując otrzymane relacje otrzymujemy:

$$Hv = Hv_1 + Hv_2 = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}w + \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'v_2 = \mathbb{X}w = v_1$$

Wobec założonej dowolności wektora v , uzyskujemy ostatecznie, że macierz H rzutuje na przestrzeń rozpiętą przez kolumny macierzy \mathbb{X} .

Rozkłady \hat{Y} oraz e

Łatwo pokazać (przez analogiczne przekształcenia), że macierz $\mathbb{I} - H$ jest macierzą rzutu ortogonalnego na przestrzeń ortogonalną do $Lin(\mathbb{X})$. W konsekwencji otrzymujemy, że predykcja \hat{Y} oraz wektor residuów e dane wzorami:

$$\hat{Y} = HY; \quad e = (\mathbb{I} - H)Y$$

są rozkładem wektora Y na dwie ortogonalne składowe: leżącą w przestrzeni $Lin(\mathbb{X})$ (wekt. \hat{Y}) i w przestrzeni ortogonalnej do niej (wekt. e).

Rozkłady \hat{Y} oraz e

Łatwo pokazać (przez analogiczne przekształcenia), że macierz $\mathbb{I} - H$ jest macierzą rzutu ortogonalnego na przestrzeń ortogonalną do $\text{Lin}(\mathbb{X})$. W konsekwencji otrzymujemy, że predykcja \hat{Y} oraz wektor residuów e dane wzorami:

$$\hat{Y} = HY; \quad e = (\mathbb{I} - H)Y$$

są rozkładem wektora Y na dwie ortogonalne składowe: leżącą w przestrzeni $\text{Lin}(\mathbb{X})$ (wekt. \hat{Y}) i w przestrzeni ortogonalnej do niej (wekt. e).

Korzystając z powyższych wzorów oraz z faktu że $Y \sim N(\mathbb{X}\beta, \sigma^2\mathbb{I})$, w natychmiastowy sposób otrzymujemy rozkłady obu wektorów:

Rozkłady \hat{Y} oraz e

Predykcja \hat{Y} oraz wektor residuów e mają następujące rozkłady:

$$\hat{Y} \sim N(\mathbb{X}\beta, \sigma^2 H); \quad e \sim N(0, \sigma^2(\mathbb{I} - H))$$

Na mocy powyższej zależności łatwo zauważyć, że elementy wektora e są skorelowane! (inaczej niż elementy wektora błędów losowych ϵ).

Rozkład estymatora s^2

Przypomnijmy, że estymator wariancji błędów losowych s^2 jest funkcją wektora residuów e i dany jest wzorem:

$$s^2 = \frac{1}{n-p} \|e\|_2^2$$

Można pokazać natępującą własność estymatora s^2 :

Rozkład estymatora s^2

Jeżeli wyrazimy estymator s^2 w następujący sposób:

$$s^2 = \sigma^2 \frac{K}{n-p}$$

Wówczas K jest zmienną losową z rozkładu χ^2 z $n-p$ stopniami swobody. Wykorzystując zależność pomiędzy s^2 i e otrzymujemy:

$$K = \left\| \frac{e}{\sigma} \right\|_2^2 \sim \chi_{n-p}^2$$

Rozkład estymatora s^2

dowód

Pokażemy, że $\|e/\sigma\|_2^2 \sim \chi_{n-p}^2$. W pierwszym kroku zauważmy, iż

$$e = (\mathbb{I} - H)Y = (\mathbb{I} - H)(\mathbb{X}\beta + \epsilon) = (\mathbb{I} - H)\epsilon$$

Niech $(\mathbb{I} - H) = Q\Lambda Q'$ będzie diagonalizacją macierzy.

Q – macierz wekt. własnych, $QQ' = Q'Q = \mathbb{I}$ (izometria),

Λ – macierz diagonalna o wartościach własnych λ_i macierzy $(\mathbb{I} - H)$ na diagonalu.

Wykorzystując powyższy rozkład macierzy $(\mathbb{I} - H)$, otrzymujemy

$$\|e/\sigma\|_2^2 = \|(\mathbb{I} - H)\epsilon/\sigma\|_2^2 = \|Q(\Lambda Q'\epsilon/\sigma)\|_2^2 = (\Lambda Q'\epsilon/\sigma)' Q'Q(\Lambda Q'\epsilon/\sigma) = \|\Lambda Q'\epsilon/\sigma\|_2^2$$

W ostatnim kroku skorzystaliśmy z faktu że macierz Q jest izometrią (nie zmienia długości wektorów).

Wprowadźmy następujące oznaczenie na wektor $Z = Q'\epsilon/\sigma$. Zauważmy, że wektor Z pochodzi z wielowymiarowego standardowego rozkładu normalnego:

$$Z = (Q'/\sigma)\epsilon \sim N(0, (Q'/\sigma)\sigma^2\mathbb{I}(Q'/\sigma)') = N(0, Q'Q) = N(0, \mathbb{I})$$

Otrzymujemy zatem, że badane wyrażenie jest ważoną sumą kwadratów niezależnych zmiennych losowych ze standardowego rozkładu normalnego:

$$\|e/\sigma\|_2^2 = \|\Lambda Q'\epsilon/\sigma\|_2^2 = \|\Lambda Z\|_2^2 = \sum_{i=1}^n \lambda_i Z_i^2$$

Rozkład estymatora s^2

Pozostaje zbadać własności wartości własnych λ_i ($\|e/\sigma\|_2^2 = \sum_{i=1}^n \lambda_i Z_i^2$). Fakt, iż macierz $(\mathbb{I} - H)$ jest macierzą rzutu ortogonalnego implikuje że jej wartości własne λ_i muszą być równe 0 lub 1.

Niech P – rzut ort. Ponieważ $P^2 = P$ zatem dla dowolnego wektora własnego v_i i stowarzyszonej z nim wartości własnej λ_i mamy $\lambda_i v_i = P v_i = (PP)v_i = P(Pv_i) = P(\lambda_i v_i) = \lambda_i (Pv_i) = \lambda_i^2 v_i$, stąd $\lambda_i^2 v_i - \lambda_i v_i = 0 \Rightarrow \lambda_i(\lambda_i - 1) = 0 \Rightarrow \lambda_i \in \{0, 1\}$

Korzystając z własności, że ślad z macierzy jest równy sumie jej wartości własnych, możemy wyznaczyć liczbę wartości własnych równych 1 w $(\mathbb{I} - H)$:

$$\begin{aligned}\sum_{i=1}^n \lambda_i &= \text{Tr}(\mathbb{I} - H) = \text{Tr}(\mathbb{I}_{n \times n}) - \text{Tr}(H) = n - \text{Tr}(\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}') = \\ &= n - \text{Tr}((\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}) = n - \text{Tr}(\mathbb{I}_{p \times p}) = n - p\end{aligned}$$

gdzie między pierwszą a drugą linią skorzystaliśmy z cykliczności śladu macierzy $\text{Tr}(ABC) = \text{Tr}(BCA)$

Ostatecznie uzyskujemy że $n - p$ wartości własnych jest równa 1 oraz p jest równa 0. W konsekwencji:

$$\|e/\sigma\|_2^2 = \sum_{i=1}^n \lambda_i Z_i^2 = \sum_{\{i: \lambda_i=1\}} 1 * Z_i^2 + \sum_{\{i: \lambda_i=0\}} 0 * Z_i^2 = \sum_{\{i: \lambda_i=1\}} Z_i^2 \sim \chi_{n-p}^2$$

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne**
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Testowanie dotyczące wektora parametrów β

Poznaliśmy już własności estymatorów $\hat{\beta}$ i s^2 :

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbb{X}'\mathbb{X})^{-1}); \quad s^2 = \frac{1}{n-p} \|e\|_2^2$$

Przy ich pomocy możemy testować istotność dowolnej kombinacji liniowej elementów wektora parametrów β . Niech $c = (c_0, \dots, c_{p-1})' \in \mathbb{R}^p$ i $d \in \mathbb{R}$.

Wówczas:

$$H_0 : c'\beta - d = 0 \quad \text{vs} \quad H_1 : c'\beta - d \neq 0$$

Statystyka testowa dla powyższego zagadnienia ma postać:

$$T = \frac{c'\hat{\beta} - d}{s(c'\hat{\beta})} \quad \text{gdzie} \quad s^2(c'\hat{\beta}) = s^2 c'(\mathbb{X}'\mathbb{X})^{-1} c$$

Statystyka T przy założeniu prawdziwości hipotezy H_0 , ma rozkład studenta z $n - p$ stopniami swobody. W konsekwencji będziemy odrzucać H_0 na poziomie istotności α , jeżeli $|T| > t_c$ gdzie $t_c = t^*(1 - \alpha/2, n - p)$ jest kwantylem rzędu $1 - \alpha/2$ z rozkładu studenta z $n - p$ stopniami swobody.

p-wartość dla tego problemu:

$p = P(|z| > |T|) = 2(1 - F_z(|T|))$, gdzie $z \sim t(n - p)$ i F_z – dystrybuanta zmiennej los. z .

Ważne przykłady

Do czego nam się przydaje taki "egzotyczny" test?

Ważne przykłady

Do czego nam się przydaje taki "egzotyczny" test?

Przy jego pomocy unifikujemy kilka poznanych wcześniej testów:

Ważne przykłady

Do czego nam się przydaje taki "egzotyczny" test?

Przy jego pomocy unifikujemy kilka poznanych wcześniej testów:

Przykład 1 (Testowanie istotności parametru β_i)

Jeżeli $c = (0, \dots, 0, 1, 0, \dots, 0)'$, gdzie wartość 1 odpowiada parametrowi β_i oraz $d = 0$. Wówczas $c'\beta - d = \beta_i$ i zagadnienie testowe sprowadza się do postaci:

$$H_0 : \beta_i = 0 \quad \text{vs} \quad H_1 : \beta_i \neq 0$$

a statystyka testowa ma postać:

$$T_i = \frac{\hat{\beta}_i}{s(\hat{\beta}_i)} \quad \text{gdzie} \quad s^2(\hat{\beta}_i) = s^2(\mathbb{X}'\mathbb{X})_{i+1,i+1}^{-1}$$

Przykład 2 (Testowanie dotyczące $E(\tilde{Y}_h)$)

Jeżeli chcemy przeprowadzić testowanie dotyczące wartości oczekiwanej ze zmiennej objaśnianej $E(\tilde{Y}_h) = \tilde{\mathbf{X}}_h \beta = \tilde{\mu}_h$ wystarczy, że za wektor c wstawimy ciąg wartości zmiennych objaśniających stowarzyszonych z \tilde{Y}_h , $c = (1, \tilde{X}_{h1}, \dots, \tilde{X}_{hp-1})' = \tilde{\mathbf{X}}_h'$. Wówczas $c'\beta - d = \tilde{\mu}_h - d$ i zagadnienie testowe sprowadza się do postaci:

$$H_0 : \tilde{\mu}_h - d = 0 \quad \text{vs} \quad H_1 : \tilde{\mu}_h - d \neq 0$$

a statystyka testowa ma postać:

$$T = \frac{\hat{\tilde{\mu}}_h - d}{s(\hat{\tilde{\mu}}_h)} \quad \text{gdzie} \quad \hat{\tilde{\mu}}_h = \tilde{\mathbf{X}}_h \hat{\beta} \quad \text{i} \quad s^2(\hat{\tilde{\mu}}_h) = s^2 \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h'$$

Uzasadnienie rozkładu statystyki T

Dla regresji liniowej prostej fakt opisujący rozkład statystyki T został podany bez uzasadnienia. Obecnie pokażemy go, w ścisły sposób.

Uzasadnienie rozkładu statystyki T

Dla regresji liniowej prostej fakt opisujący rozkład statystyki T został podany bez uzasadnienia. Obecnie pokażemy go, w ścisły sposób.

Z definicji zmienną losową z rozkładu studenta o k stopniach swobody można wyrazić jako iloraz niezależnych zmiennych losowych: $\tilde{T} = \frac{\tilde{Z}}{\sqrt{\tilde{K}/k}}$ ma rozkład stud. z k st. swob. gdy $\tilde{Z} \sim N(0, 1)$; $\tilde{K} \sim \chi_k^2$; $\tilde{Z} \perp \tilde{K}$

Statystykę T możemy wyrazić w następujący sposób:

$$T = \frac{c' \hat{\beta} - d}{\sqrt{s^2 c' (\mathbb{X}' \mathbb{X})^{-1} c}} = \frac{(c' \hat{\beta} - d) / \left(\sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right)}{\sqrt{s^2 / \sigma^2}}$$

Zauważmy, że przy H_0 licznik i mianownik mają odpowiednie rozkłady:

$$c' \hat{\beta} \sim N(d, \sigma^2 c' (\mathbb{X}' \mathbb{X})^{-1} c) \Rightarrow (c' \hat{\beta} - d) / \left(\sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right) \sim N(0, 1)$$

$$s^2 / \sigma^2 = \frac{1}{n-p} \left\| \frac{e}{\sigma} \right\|_2^2 \text{ oraz } \left\| \frac{e}{\sigma} \right\|_2^2 = K \sim \chi_{n-p}^2$$

Uzasadnienie rozkładu statystyki T

Dla regresji liniowej prostej fakt opisujący rozkład statystyki T został podany bez uzasadnienia. Obecnie pokażemy go, w ścisły sposób.

Z definicji zmienną losową z rozkładu studenta o k stopniach swobody można wyrazić jako iloraz niezależnych zmiennych losowych: $\tilde{T} = \frac{\tilde{Z}}{\sqrt{\tilde{K}/k}}$ ma rozkład stud. z k st. swob. gdy $\tilde{Z} \sim N(0, 1)$; $\tilde{K} \sim \chi_k^2$; $\tilde{Z} \perp \tilde{K}$

Statystykę T możemy wyrazić w następujący sposób:

$$T = \frac{c' \hat{\beta} - d}{\sqrt{s^2 c' (\mathbb{X}' \mathbb{X})^{-1} c}} = \frac{(c' \hat{\beta} - d) / \left(\sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right)}{\sqrt{s^2 / \sigma^2}}$$

Zauważmy, że przy H_0 licznik i mianownik mają odpowiednie rozkłady:

$$c' \hat{\beta} \sim N(d, \sigma^2 c' (\mathbb{X}' \mathbb{X})^{-1} c) \Rightarrow (c' \hat{\beta} - d) / \left(\sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right) \sim N(0, 1)$$

$$s^2 / \sigma^2 = \frac{1}{n-p} \left\| \frac{e}{\sigma} \right\|_2^2 \text{ oraz } \left\| \frac{e}{\sigma} \right\|_2^2 = K \sim \chi_{n-p}^2$$

Pozostaje zbadać niezależność. W tym celu wystarczy pokazać niezależność $\hat{\beta}$ i e :

$$\begin{aligned} \text{Cov}(e, \hat{\beta}) &= \text{Cov}((\mathbb{I} - H)Y, (\mathbb{X}' \mathbb{X})^{-1} \mathbb{X}' Y) = (\mathbb{I} - H) \text{Cov}(Y, Y) \mathbb{X} (\mathbb{X}' \mathbb{X})^{-1} = \\ &= (\mathbb{I} - H)(\sigma^2 \mathbb{I}) \mathbb{X} (\mathbb{X}' \mathbb{X})^{-1} = \sigma^2 (\mathbb{X} - H \mathbb{X}) (\mathbb{X}' \mathbb{X})^{-1} = 0 \end{aligned}$$

Wektory $\hat{\beta}$ i e są nieskorelowane i mają normalne rozkłady (jako przekształt. wekt. Y), stąd są również niezależne. Dodatkowo, własność ta jest dziedziczona na licznik i mianownik jako przekształcenia odpowiednich wektorów (licznik = $f_1(\hat{\beta})$; mianownik = $f_2(e)$).

Przedziały ufności

Na podstawie statystyki T możemy również skonstruować przedział ufności o współczynniku ufności $1 - \alpha$ dla kombinacji liniowej $c'\beta$:

$$c'\hat{\beta} \pm t_c s(c'\hat{\beta})$$

gdzie $s^2(\hat{\beta}_i) = s^2 c'(\mathbb{X}'\mathbb{X})^{-1}c$ oraz $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$ jest kwantylem rzędu $1 - \frac{\alpha}{2}$ z rozkładu studenta z $n - p$ stopniami swobody.

Przedziały ufności

Na podstawie statystyki T możemy również skonstruować przedział ufności o współczynniku ufności $1 - \alpha$ dla kombinacji liniowej $c'\beta$:

$$c'\hat{\beta} \pm t_c s(c'\hat{\beta})$$

gdzie $s^2(\hat{\beta}_i) = s^2 c'(\mathbb{X}'\mathbb{X})^{-1}c$ oraz $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$ jest kwantylem rzędu $1 - \frac{\alpha}{2}$ z rozkładu studenta z $n - p$ stopniami swobody.

Przykład 1 (przedział ufności dla parametru β_i ; $c = (0, \dots, 0, 1, 0, \dots, 0)'$):

$$\hat{\beta}_i \pm t_c s(\hat{\beta}_i) \text{ gdzie } s^2(\hat{\beta}_i) = s^2(\mathbb{X}'\mathbb{X})_{i+1,i+1}^{-1}$$

Przykład 2 (przedział ufności dla $\tilde{\mu}_h$; $c = (1, \tilde{X}_{h1}, \dots, \tilde{X}_{hp-1})' = \tilde{\mathbb{X}}_h'$):

$$\hat{\mu}_h \pm t_c s(\hat{\mu}_h) \text{ gdzie } \hat{\mu}_h = \tilde{\mathbb{X}}_h' \hat{\beta} \text{ i } s^2(\hat{\mu}_h) = s^2 \tilde{\mathbb{X}}_h' (\mathbb{X}'\mathbb{X})^{-1} \tilde{\mathbb{X}}_h.$$

Przedział predykcyjny dla nowej obserwacji \tilde{Y}_h

Wykonując podobne rozumowanie możemy wyznaczyć przedział predykcyjny na poziomie $1 - \alpha$ dla nowej obserwacji \tilde{Y}_h . Jest on postaci:

$$\hat{\mu}_h \pm t_c s(pred) \quad \text{gdzie} \quad \hat{\mu}_h = \tilde{\mathbf{X}}_h \hat{\boldsymbol{\beta}} \quad \text{i} \quad s^2(pred) = s^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$$

gdzie $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$ jest kwantylem rzędu $1 - \frac{\alpha}{2}$ z rozkładu studenta z $n - p$ stopniami swobody.

Przedział predykcyjny dla nowej obserwacji \tilde{Y}_h

Wykonując podobne rozumowanie możemy wyznaczyć przedział predykcyjny na poziomie $1 - \alpha$ dla nowej obserwacji \tilde{Y}_h . Jest on postaci:

$$\hat{\mu}_h \pm t_c s(pred) \quad \text{gdzie} \quad \hat{\mu}_h = \tilde{\mathbf{X}}_h \hat{\beta} \quad \text{i} \quad s^2(pred) = s^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$$

gdzie $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$ jest kwantylem rzędu $1 - \frac{\alpha}{2}$ z rozkładu studenta z $n - p$ stopniami swobody.

szkic dowodu

Chcemy pokazać że:

$$P(\hat{\mu}_h - t_c s(pred) < \tilde{Y}_h < \hat{\mu}_h + t_c s(pred)) = 1 - \alpha$$

Łatwo pokazać że:

$$P(\hat{\mu}_h - t_c s(pred) < \tilde{Y}_h < \hat{\mu}_h + t_c s(pred)) = P\left(\left|\frac{\tilde{Y}_h - \hat{\mu}_h}{s(pred)}\right| < t_c\right)$$

Wiemy, że zmienna losowa \tilde{Y}_h ma rozkład $N(\tilde{\mathbf{X}}_h \beta, \sigma^2)$ i jako nowa obserwacja jest niezależna od $\hat{\mu}_h \sim N(\tilde{\mathbf{X}}_h \beta, \sigma^2 \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$. Stąd:

$$E(\tilde{Y}_h - \hat{\mu}_h) = 0$$

$$\sigma^2(pred) = \text{var}(\tilde{Y}_h - \hat{\mu}_h) = \text{var}(\tilde{Y}_h) + \text{var}(\hat{\mu}_h) = \sigma^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$$

Łatwo zauważyć, że $s^2(pred)$ jest estymatorem $\sigma^2(pred)$. Ponadto jest on zmienną losową niezależną od $\tilde{Y}_h - \hat{\mu}_h$ ($\hat{\mu}_h$ jest funkcją $\hat{\beta}$ a \tilde{Y}_h jest nową niezależną obserwacją). Zatem:

$$\frac{\tilde{Y}_h - \hat{\mu}_h}{s(pred)} = \frac{(\tilde{Y}_h - \hat{\mu}_h) / \sqrt{\sigma^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')}}}{\sqrt{\frac{s^2}{\sigma^2}}} \sim N(0, 1) \\ \sim \sqrt{\chi_{n-p}^2 / (n - p)}$$

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji**
- 7 Współczynnik determinacji oraz jego modyfikacja

Analiza wariancji dla regresji liniowej jest metodą uporządkowania zmienności w wektorze odpowiedzi $Y = (Y_1, \dots, Y_n)'$. Są dwa źródła zmienności:

- zmienność wynikająca z błędów losowych $\epsilon_i \sim N(0, \sigma^2)$ powiązana z wielkością parametru σ^2 ,
- zmienność, której źródłem są różnice w wartościach oczekiwanych zmiennych objaśnianych $E(Y_i) = \mu_i = \beta_0 + X_{i1}\beta_1 + \dots + X_{ip-1}\beta_{p-1}$.

Analiza wariancji

Do analizy zmienności w wektorze odpowiedzi Y wykorzystywaliśmy w regresji liniowej prostej, poniższe statystyki (dla wartości $p = 2$):

Source	SS	df	MS
Model	$SSM = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$	$dfM = p - 1$	$MSM = SSM/dfM$
Error	$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$	$dfE = n - p$	$MSE = SSE/dfE = s^2$
Total	$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2$	$dfT = n - 1$	$MST = SST/dfT$
Relations	$SST = SSM + SSE$	$dfT = dfM + dfE$	$MST \neq MSM + MSE$

Całość rozumowania w przypadku regresji liniowej wielorakiej jest taka sama z tą różnicą, że w tym przypadku liczba stopni swobody statystyk SSM i SSE zależy od liczby kolumn p .

Liczba stopni swobody

Uzasadnimy obecnie skąd bierze się kolumna z liczbą stopni swobody. Jest ona równa śladowi macierzy, na którą wykonywany jest rzut ortogonalny wektora Y związany z odpowiednimi sumami kwadratów SSM , SSE oraz SST .

Uzasadnimy obecnie skąd bierze się kolumna z liczbą stopni swobody. Jest ona równa śladowi macierzy, na którą wykonywany jest rzut ortogonalny wektora Y związany z odpowiednimi sumami kwadratów SSM , SSE oraz SST .

Zacznijmy od statystyki SSE , gdyż dla niej do pewnego stopnia analiza już została wykonana. Zauważmy, że:

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \|Y - \hat{Y}\|_2^2 = \|(\mathbb{I} - H)Y\|_2^2 = \|e\|_2^2$$

Z wcześniejszej analizy wiemy dodatkowo, że ślad macierzy rzutu ortogonalnego $Tr(\mathbb{I} - H) = n - p$.

W analogiczny sposób możemy potraktować statystykę SST. Wystarczy zauważyć, że jest ona tożsama ze statystyką SSE dla szczególnej macierzy rzutu \tilde{H} :

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \|(\mathbb{I} - \tilde{H})Y\|_2^2 = \|\tilde{e}\|_2^2$$

gdzie \tilde{H} jest rzutem ortogonalnym na przestrzeń rozpiętą na kolumnie jedynek związanej z intercepem $Lin(\mathbb{1} = (1, \dots, 1)')$ (brak zmiennych objaśnianych).

$$\tilde{H} = \mathbb{1}(\mathbb{1}'\mathbb{1})^{-1}\mathbb{1}' = \frac{1}{n}\mathbb{1}\mathbb{1}' = \begin{pmatrix} 1/n & \cdots & 1/n \\ \vdots & \ddots & \vdots \\ 1/n & \cdots & 1/n \end{pmatrix}; \quad \tilde{H}Y = \begin{pmatrix} \bar{Y} \\ \vdots \\ \bar{Y} \end{pmatrix}$$

Łatwo pokazać, że $Tr(\tilde{H}) = 1$, dlatego $dfT = Tr(\mathbb{I} - \tilde{H}) = n - 1$.

Liczba stopni swobody

W przypadku statystyki SSM wykorzystamy wyniki dla poprzednich punktów

$$SSM = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \|(H - \tilde{H})Y\|_2^2$$

Stąd $dfM = \text{Tr}(H - \tilde{H}) = \text{Tr}(H) - \text{Tr}(\tilde{H}) = p - 1$.

Wypada wykazać że $H - \tilde{H}$ jest macierzą rzutu ortogonalnego. Symetryczność jest oczywista, także pozostaje wykazać idempotentność. Jednakże w pierwszej kolejności należy zauważyć że:

$$H\tilde{H} = \tilde{H} \text{ oraz } \tilde{H}H = \tilde{H}$$

Powyższe równości wynikają bezpośrednio z faktu, iż przestrzeń $\text{Lin}(\mathbb{1})$ (na którą rzutuje \tilde{H}) jest podprzestrzenią $\text{Lin}(\mathbb{X})$ (na którą rzutuje H). Wykorzystując powyższe fakty uzyskujemy idempotentność macierzy $H - \tilde{H}$:

$$(H - \tilde{H})^2 = H^2 - H\tilde{H} - \tilde{H}H + \tilde{H}^2 = H - \tilde{H}$$

Test F

Na podstawie statystyk MSM i MSE skonstruowany jest tzw. test F testujący hipotezę o istotności wpływu wszystkich regresorów (równocześnie):

$$H_0 : \beta_1 = \dots = \beta_{p-1} = 0 \quad \text{vs} \quad H_1 : \beta_i \neq 0 \text{ przynajmniej dla jednego } i$$

Odrzucamy hipotezę zerową, gdy $F = MSM/MSE > F_c$, gdzie $F_c = F^*(1 - \alpha, dfM, dfE)$ jest kwantylem rzędu $1 - \alpha$ z rozkładu Fishera–Snedecora z dfM i dfE stopniami swobody.

Na podstawie statystyk MSM i MSE skonstruowany jest tzw. test F testujący hipotezę o istotności wpływu wszystkich regresorów (równocześnie):

$$H_0 : \beta_1 = \dots = \beta_{p-1} = 0 \quad \text{vs} \quad H_1 : \beta_i \neq 0 \text{ przynajmniej dla jednego } i$$

Odrzucamy hipotezę zerową, gdy $F = MSM/MSE > F_c$, gdzie $F_c = F^*(1 - \alpha, dfM, dfE)$ jest kwantylem rzędu $1 - \alpha$ z rozkładu Fishera-Snedecora z dfM i dfE stopniami swobody.

Zwykle, wnioskowanie dokonywane jest na podstawie p-wartości:

$p = P(z > F) = 1 - \tilde{F}_z(F)$, gdzie $z \sim F(dfM, dfE)$ a \tilde{F}_z jest dystrybuantą zm. z.

Na podstawie statystyk MSM i MSE skonstruowany jest tzw. test F testujący hipotezę o istotności wpływu wszystkich regresorów (równocześnie):

$$H_0 : \beta_1 = \dots = \beta_{p-1} = 0 \quad \text{vs} \quad H_1 : \beta_i \neq 0 \text{ przynajmniej dla jednego } i$$

Odrzucamy hipotezę zerową, gdy $F = MSM/MSE > F_c$, gdzie $F_c = F^*(1 - \alpha, dfM, dfE)$ jest kwantylem rzędu $1 - \alpha$ z rozkładu Fishera-Snedecora z dfM i dfE stopniami swobody.

Zwykle, wnioskowanie dokonywane jest na podstawie p-wartości:

$$p = P(z > F) = 1 - \tilde{F}_z(F), \text{ gdzie } z \sim F(dfM, dfE) \text{ a } \tilde{F}_z \text{ jest dystrybuantą zm. z.}$$

Na hipotezy w testie F można również spojrzeć jak na porównanie dwóch modeli:

$$H_0 : \text{ dane pochodzą z modelu } Y_i = \beta_0 + \epsilon_i \text{ (tzw. model zredukowany)}$$

$$H_1 : \text{ dane pochodzą z modelu } Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_{p-1} X_{ip-1} + \epsilon_i \text{ (tzw. model pełny)}$$

Tabela analizy wariancji (ANOVA Table)

Dane potrzebne do wykonania testu F zwykle przedstawiane są w tzw. tabeli analizy wariancji, o następującej postaci:

	df	SS	MS	F	p-value
Model	df_M	SS_M	MS_M	$F = MS_M / MSE$	$p = P(z > F)$
Error	df_E	SSE	MSE		

Uwagi o teście F :

- gdy zachodzi hipoteza alternatywna statystyka F pochodzi z niecentralnego rozkładu Fishera–Snedecora,
- umożliwia to wyznaczenie funkcji mocy testu,
- gdy $p = 2$ (mamy jedną zm. objaśniającą) test F i test oparty na statystyce T dla parametru β_1 są równoważne.

Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne
- 6 Analiza wariancji
- 7 Współczynnik determinacji oraz jego modyfikacja

Współczynnik determinacji R^2

Współczynnik determinacji R^2 jest miarą jakości dopasowania modelu. Mówi on o tym, jaką część całkowitej zmienności w wektorze Y (SST) stanowi zmienność wyjaśniona przez model (SSM).

$$R^2 = SSM/SST = 1 - SSE/SST$$

Przyjmuje on wartości od 0 do 1 (czasami wyrażany jest w skali procentowej).

Współczynnik determinacji R^2

Współczynnik determinacji R^2 jest miarą jakości dopasowania modelu. Mówi on o tym, jaką część całkowitej zmienności w wektorze Y (SST) stanowi zmienność wyjaśniona przez model (SSM).

$$R^2 = SSM/SST = 1 - SSE/SST$$

Przyjmuje on wartości od 0 do 1 (czasami wyrażany jest w skali procentowej).

- Przy użyciu statystyki R^2 możemy porównywać modele o tej samej liczbie regresorów (również w regresji wielorakiej),
- czasami gdy porównujemy modele o różnej liczbie regresorów, zamiast R^2 używa się tzw. modyfikowanego współczynnika determinacji:

$$\tilde{R}^2 = 1 - MSE/MST$$

istnieją jednak lepsze metody.